

Data Mesh und Data Engineering **(2/6)**

Data Mesh

Prof. Dr. Arthur Vetter

Folgende Inhalte werden behandelt

1. OLTP vs. OLAP

2. Data Mesh

3. Data Engineering

4. Open Table Format

5. Parquet

6. Data Contracts

Literatur

- Dehghani, Zhamak. Data Mesh: Delivering Data-Driven Value at Scale. O'Reilly Media, 2022.

Lernziele

- Die Kernideen vom Data Mesh verstehen

Das Idee des Data Meshs ist noch relativ jung

- Erfinderin des Data Mesh-Ansatzes
- Die ersten Ideen (2019) wurden auf dem Blog von Martin Fowler veröffentlicht:
 - <https://martinfowler.com/articles/data-monolith-to-mesh.html>
 - <https://martinfowler.com/articles/data-mesh-principles.html>
- 2022: Veröffentlichung des Buchs „Data Mesh: Delivering Data-Driven Value at Scale“
- Hat ihr eigenes Unternehmen gegründet, um die Idee mit einem Produkt weiter voranzutreiben:
<https://www.nextdata.com>



<https://www.thoughtworks.com/en-de/profiles/z/zhamak-dehghani>


Übung 1: Lesen Sie das Kapitel „Data Mesh in a Nutshell“ aus dem Buch durch und beantworten Sie folgende Fragen

- Der Link zum Kapitel ist in Moodle hinterlegt
- Ist Data Mesh eine Technologie?
- Was sind die Prinzipien des Data Meshs?
- Was sind die Trade-Offs (Chance und Risiken) der einzelnen Prinzipien und wie werden die Risiken mitigiert?
- An welchen Paradigmen aus der OLTP-Welt orientiert sich das Data Mesh?


Ist Data Mesh eine Technologie?

- Data Mesh ist keine Technologie
- Operating Model und Architektur
- Hat wiederum Implikationen auf Technologie, um das Konzept umzusetzen

Die geänderte Sicht der aktuell häufig anzutreffenden Sicht in Unternehmen zum Data Mesh



Die vier Prinzipien



Das Beispielunternehmen Daff


Daff is organized around business units that it refers to as *domains*. The **player** domain focuses on the core music player used on mobile devices, the **partnership** domain works with business partners such as exercise applications and art venues, and the **playlist** domain investigates advanced approaches for generating playlists. Each domain combines software development and broader business capabilities and is responsible for the software components that support that domain.

Walking around Daff you notice that at any point in time, there are many concurrent experiments being run by each domain to improve their applications and services. For example, **player** teams are continuously experimenting with better engagement with users. The **partnership** domain team is experimenting with data captured from a variety of external sources such as **exercise platforms**, **art venues**, etc. The **playlist** teams keep applying more advanced machine learning in curating and recommending engaging compilations. And the **artist** domain team is utilizing machine learning to discover, attract, and onboard artists who normally would have gone unnoticed.

Every domain of the business and their collaborating technology teams have a deep appreciation for meaningful, trustworthy, and secure data. Not only that, everyone has an expectation that on-demand access to data across the organization is a norm. They know their role in making that happen. They are all responsible for data and have a stake in it.

Every domain is enthusiastically applying machine learning models wherever the feature or the function of the domain can be implemented through the exploitation of past data and patterns in it. For example, the **playlist** teams are using generative machine learning models to create weird and wonderful compilations. The compilations are targeted for different activities, from running to focusing on learning. The **artist** team is exploiting multiple datasets from social media and other agencies outside of Daff to detect emerging artists and onboard, promote, and connect them with their new audience.

1. Prinzip: Domain Driven Ownership




- Angelehnt an Domain Driven Design aus der OLTP-Welt
- Ein Datenmodell für das ganze Unternehmen ist unrealistisch → das ist das Gegenteil von DDD
- Die Teams und ihre Applikationen und Daten werden nach einer Domäne organisiert
- Kommunikation zwischen Teams wird damit auf ein Minimum reduziert (nur die Schnittstellen werden ausgehandelt)
- So wird Skalierbarkeit sichergestellt

Die drei Typen von Daten

Source-aligned


Aggregate

Consumer-Aligned




2. Prinzip: Data as a Product

- Unterschied zu anderen Produkten: Die Use Cases sind teilweise unklar, die das Datenprodukt verwenden werden
- → Ziel: Es für möglichst viele einfach machen, aber nicht für jeden. Use Cases können die Daten selbst dann weiter anpassen bei Bedarf




Baseline Attribute eines Datenprodukts




Data Product as an Architecture Quantum

An architectural quantum, defined in Building Evolutionary Architectures (O'Reilly), is the smallest unit of architecture that can be independently deployed, has high functional cohesion, and includes all the “structural elements required for its function.”


Interne Sicht



Äußere Sicht




Sharing Data Products



3. Prinzip: Self-Serve Data Platform


- Ziel Reduktion Cognitive Load
- Anspruch: Generalist Technologist soll es nutzen können
- Aktuelle Challenge: operative Teams nutzen Java, Kafka, MongoDB, Postgres, API, Microservice
- Data Analytics: Spark, Impala, Iceberg, Nifi, Streaming, etc,
- Domain Agnostic

Eine Plattform sollte die zentral benötigten Komponenten zum Aufbau und zur Nutzung von Datenprodukten bereitstellen




Data Mesh Plattform im Vergleich zu bisherigen Ansätzen

Data mesh



Serve autonomous domain-oriented teams




Manage autonomous interoperable data products (with code, data, policy as one unit)




Integrated platform of operational and analytical capabilities

Others



Serve a centralized data team for all domains



Manage data, pipelines, code, and policies separately




Two independent stacks for operational and analytical systems with point-to-point integrations

Data mesh



Designed for a generalist majority



Favor decentralized technologies




Domain agnostic

Others



Designed for a specialist majority



Favor centralized technologies




Domain aware

4. Prinzip: Federated Governance

- Ziel ist wie bei den alten Modellen
- Hohe Datenqualität, gute Datenbeschreibungen, Einhaltung von Compliance Richtlinien (DSGVO, Data Act, AI-Act, interne Richtlinien)
- Klare Ansprechpartner
- Wie die Ziele erreicht werden unterscheidet sich

Operating model




Globale vs. Lokale Policies

- Globale Policies gelten für alle Datenprodukte (z.B. Sharing von strukturierten Daten im Open Table Format)
- Lokale Policies werden von einem Datenprodukt-Team definiert, z.B. wie Daten abgefragt werden sollten, um Kosten zu reduzieren

Ein zentraler Bestandteil ist Automatisierung

- Nur durch Automatisierung lässt sich die Einhaltung von Policies enforced
- Standards als Code bereitstellen, z.B. durch Templates
- Policies as Code, um z.B. gewisse Compliance-Anforderungen zu enforced
- Beispiel: Jemand möchte ein gewisses Datenprodukt für einen Use Case verwenden → abprüfen der Compliance gegen die definierten Eigenschaften im Datenprodukt
- Automatisierte Tests, ob Datendokumentation auch der Realität auf einer Datenplattform entspricht

Recap die vier Prinzipien und die Trade-offs



Übung2: Finden Sie die Konzepte in entropy data wieder

- Klicken Sie sich durch <https://demo.entropy-data.com/> und versuchen Sie die vorgestellten Konzepte wiederzufinden

Zusammenfassung

- Die zentralen Prinzipien eines Data Meshs sind
 - Domain Ownership
 - Data as a Product
 - Self-Serve Data Platform
 - Federated Governance
- Die einzelnen Prinzipien bergen verschiedene Risiken, weswegen alle vier benötigt werden, um diese zu mitigieren