

Data Mesh und Data Engineering

Portfolioprüfung

Prof. Dr. Arthur Vetter

Organisatorisches – Gruppenorganisation

- 5 Gruppen von je ca. 4 Personen – Meldung bis heute 23:59 Uhr
- Eine Note für die gesamte Gruppe. Die Note setzt sich wie folgt zusammen:
 - Abschlusspräsentation inkl. Fragerunde in der letzten Vorlesungsstunde, je Gruppe 25 Minuten (15 Minuten Präsentation, 10 Minuten Fragen) – 30 Punkte
 - Eingereichte Arbeitsergebnisse (Code und eine Readme, in der beschrieben ist wie der Code aufgebaut ist und zu lesen ist.) – 30 Punkte.
 - Der Code sollte idempotent lauffähig sein und folgendes beinhalten:
 - DDLs zur Erstellung des Datenmodells und Begründung, warum das Datenmodell so gestaltet wurde
 - Pipeline-Code zur Befüllung des Datenmodells, inkl. Scheduler-Code
 - Data Contract zur Beschreibung der Daten und wie das Datenprodukt verwendet werden kann
- Abgabe der schriftlichen Arbeitsergebnisse bis zum Vorabend der mündlichen Präsentation

Aufgabenstellung

- Erstellen Sie ein Datenprodukt für den bereitgestellten Datensatz auf Moodle:
- Gemeinden in Deutschland (<https://www.kaggle.com/datasets/ajaypatil047/germany-municipalities-and-districts?resource=download>) – Tabelle: project_gemeinden
- Grundstücksveräußerungsfälle (<https://www.regionalstatistik.de/genesis/online?operation=statistic&levelindex=0&levelid=1780665864248&code=61511#abreadcrumb>) – Tabelle: project_bauland
- Klimadaten (<https://www.kaggle.com/datasets/berkeleyearth/climate-change-earth-surface-temperature-data?select=GlobalLandTemperaturesByCity.csv>) – Tabelle: project_klimadaten
- Bevölkerungszahlen (<https://www.regionalstatistik.de/genesis/online?operation=statistic&levelindex=0&levelid=1780665864248&code=12411#abreadcrumb>) – Tabelle: project_bevoelkerungszahlen